

KOCAELİ ÜNİVERSİTESİ

Fen Edebiyat Fakültesi — Yapay Zeka ve Makine Öğrenmesi Bölümü

VERİ BİLİMİ İÇİN İSTATİSTİK PROJE ÖDEVİ RAPORU

Proje 2A

Email Spam Sınıflandırması

Bernoulli/Binom Dağılımı ve İstatistiksel Hipotez Testleri

Mustafa Yiğit Genç

Öğrenci No: 250121047

2025–2026 Bahar Dönemi | Mayıs 2026

1. Giriş

Email spam, internet iletişiminin yaygınlaşmasıyla birlikte önemli bir güvenlik ve kullanılabilirlik sorunu hâline gelmiştir. Günümüzde dünya genelinde iletilen emailerin önemli bir bölümünün istenmeyen içerik taşıdığı tahmin edilmekte; bu emailer yalnızca kullanıcı verimliliğini düşürmekle kalmayıp kimlik avı saldırıları ve kötü amaçlı yazılım dağıtımı gibi ciddi güvenlik tehditlerinin de taşıyıcısı olmaktadır.

Bu proje kapsamında spam tespiti problemi, salt bir makine öğrenmesi problemi olarak değil, istatistiksel olarak yorumlanabilir bir çerçevede ele alınmaktadır. Temel amaç; gözlemlenen email verilerini olasılık dağılımlarıyla modellemek, bir sınıflandırıcının başarımını istatistiksel testlerle doğrulamak ve Merkezi Limit Teoremi'nin (MLT) pratikte nasıl işlediğini göstermektir.

1.1 Veri Seti

Çalışmada UCI Machine Learning Repository'den alınan Spambase veri seti kullanılmıştır. Cranor ve LaMacchia (1998) tarafından derlenen bu veri seti, gerçek bir email hesabından elde edilen 4601 kayıttan oluşmakta ve her kayıt için 57 sayısal özellik içermektedir. Söz konusu özellikler; belirli kelimelerin email içindeki görünme yüzdesi (48 özellik), özel karakterlerin frekansı (6 özellik) ve büyük harf kullanım istatistiklerinden (3 özellik) meydana gelmektedir. Hedef değişken ikilidir: 1 (spam) ya da 0 (ham).

1.2 Amaç ve Araştırma Soruları

Projenin üç temel amacı vardır:

- Her emailin bağımsız bir Bernoulli denemesi olarak modellenmesi ve spam olma olasılığının MLE yöntemiyle tahmin edilmesi.
- Bir email kümesindeki spam sayısının Binom dağılımıyla ifade edilmesi ve bu dağılımın Normal'e yakınsadığının MLT çerçevesinde gösterilmesi.
- Gaussian Naive Bayes sınıflandırıcısının başarımının istatistiksel hipotez testleriyle sınanması.

1.3 Kullanılan Yöntemler

Analizde şu yöntemler uygulanmıştır: keşifsel veri analizi (EDA), Bernoulli/Binom dağılımı ile parametre tahmini (MLE), Gaussian Naive Bayes sınıflandırması, Binom testi, Z-testi (MLT yaklaşımı), Wilson güven aralığı hesabı, 5-Fold Cross Validation ve Shapiro-Wilk normallik testi. Tüm analizler Python 3 ile NumPy, pandas, SciPy ve scikit-learn kütüphaneleri kullanılarak gerçekleştirilmiştir.

2. Veri Keşfi

2.1 Veri Seti Özellikleri

Spambase veri seti 4601 satır ve 58 sütundan (57 özellik + 1 hedef değişken) oluşmaktadır. Veri setinde hiç eksik değer bulunmamaktadır; tüm özellik değerleri sıfır veya pozitif sayısal değerlerdir. Özellikler üç ana grupta incelenmektedir:

- Kelime frekansları (48 özellik): "make", "free", "money", "your" gibi 48 farklı kelimenin email içindeki yüzdesi. Hesaplama: $100 \times (\text{kelime sayısı} / \text{toplam kelime})$.
- Karakter frekansları (6 özellik): "!", "\$", "#" gibi özel karakterlerin email içindeki yüzdesi.
- Büyük harf istatistikleri (3 özellik): Art arda gelen büyük harf dizilerinin ortalama uzunluğu, maksimum uzunluğu ve toplam karakter sayısı.

2.2 Sınıf Dağılımı


Aşağıdaki tabloda veri setindeki sınıf dağılımı görülmektedir:

Sınıf	Email Sayısı	Oran
Ham (spam değil)	3175	%69.0
Spam	1426	%31.0
Toplam	4601	%100.0

Tablo 1. Veri setindeki spam ve ham email dağılımı ($n = 4601$).

Veri setinde %69 ham, %31 spam email bulunmaktadır. Bu oran dengeli sayılmamakla birlikte aşırı uç bir dengesizlik de değildir. Dengesizlik, özellikle precision ve recall değerleri yorumlanırken göz önünde bulundurulmalıdır. Şekil 1'de sınıf oranı ve seçili özelliklerin sınıflar arasındaki karşılaştırması görülmektedir:

Bölüm 1 — Veri Seti Genel Bakış



Şekil 1. Sol: Spam/Ham oranı. Sağ: Seçili özelliklerin spam ve ham sınıflarındaki ortalama değerleri.

Şekil 1'in sağ paneli incelendiğinde, "free", "money", "char_freq_exclaim" ve "char_freq_dollar" özelliklerinin spam emailerinde belirgin biçimde daha yüksek değerler aldığı görülmektedir. Bu özellikler sınıflandırıcının öğrenebileceği güçlü sinyaller sunmaktadır.

2.3 Betimsel İstatistikler

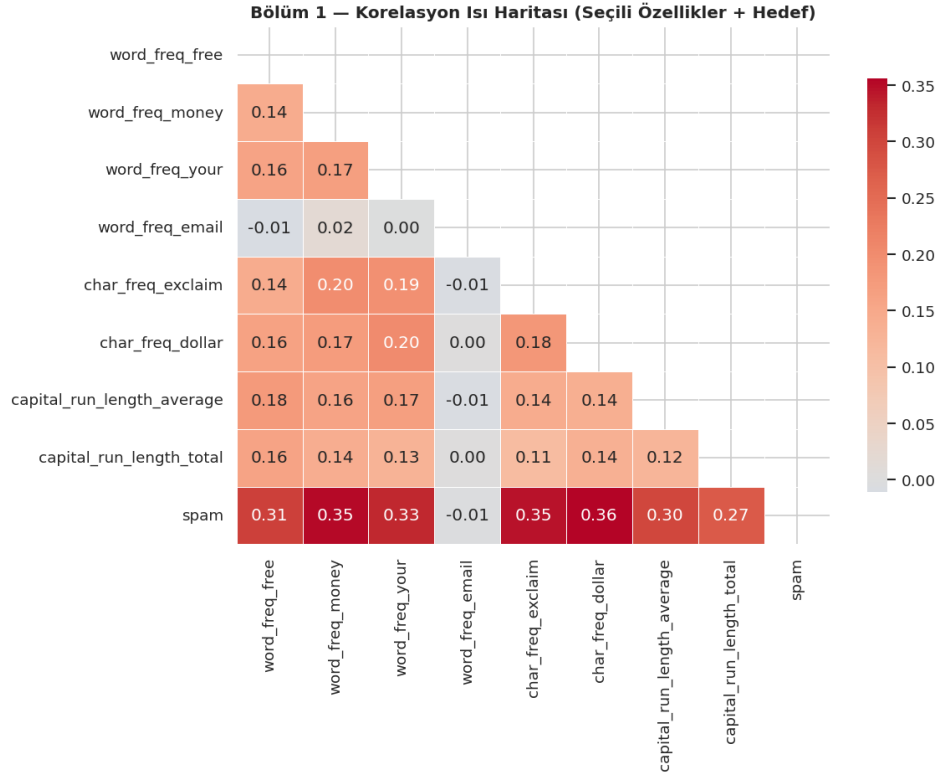
Aşağıdaki tablo, ayırt edici güce sahip olduğu düşünülen altı özellik için betimsel istatistikleri vermektedir (tüm veri seti, $n = 4601$):

Özellik	Ort.	Std.Sap.	Medyan	Maks.
word_freq_free	0.512	1.490	0.080	37.17
word_freq_money	0.529	1.445	0.080	29.01
word_freq_your	0.532	1.418	0.082	34.23
char_freq_exclaim (!)	0.533	1.457	0.078	24.67
char_freq_dollar (\$)	0.532	1.375	0.080	27.59
capital_run_length_avg	4.459	6.019	2.592	113.1

Tablo 2. Seçili özellikler için betimsel istatistikler.

Her özellik için standart sapma ortalamadan büyük ya da ona yakındır; bu durum sağa çarpık dağılımlara işaret eder. Medyan değerlerinin ortalamadan küçük olması bu çarpıklığı doğrulamaktadır: çoğu emailde belirli kelimeler hiç ya da nadiren geçerken, bazı emailerde yoğun biçimde kullanılmaktadır. capital_run_length_average özelliğinin maksimum değeri olan 113.1, bazı spam emailerde olağandışı uzun büyük harf dizileri kullanıldığını göstermektedir.

2.4 Özellikler Arası İlişkiler



Şekil 2. Seçili özellikler ve hedef değişken arasındaki Pearson korelasyon ısı haritası.

Şekil 2'de hedef değişkenle en yüksek korelasyona sahip özelliğin `char_freq_exclaim` olduğu görülmektedir; bunu `char_freq_dollar` ve `word_freq_your` takip etmektedir. Özellikler arasındaki çapraz korelasyonların genel olarak düşük kalması, Naive Bayes'in bağımsızlık varsayımı için görece uygun bir zemin oluşturmaktadır.

3. Metodoloji

3.1 Bernoulli Dağılımı ile Modelleme

Her email, bağımsız bir Bernoulli denemesi olarak modellenmektedir. $X_i = 1$ emailin spam, $X_i = 0$ ise ham olduğunu ifade etmekte; p herhangi bir emailin spam olma olasılığını temsil etmektedir:

$$X_i \sim \text{Bernoulli}(p)$$

Olasılık kütle fonksiyonu:

$$P(X_i = x) = p^x \cdot (1-p)^{1-x}, x \in \{0, 1\}$$

Beklenen değer ve varyans:

$$E[X] = p \quad \text{Var}(X) = p(1 - p)$$

3.2 Parametre Tahmini — MLE

p parametresinin tahmini için Maksimum Olabilirlik Tahmini (MLE) kullanılmıştır. Log-olabilirlik fonksiyonu maksimize edildiğinde elde edilen tahminci:

$$\hat{p} = k / n = 1426 / 4601 = 0.3099$$

Bu tahminci sapmasız ($E[\hat{p}] = p$) ve tutarlıdır ($n \rightarrow \infty$ iken $\hat{p} \rightarrow p$). Aynı zamanda Cramér-Rao alt sınırına ulaştığından sapmasız tahminciler arasında en verimli olanıdır.

3.3 Binom Dağılımı ile Modelleme

$n = 4601$ bağımsız Bernoulli denemesindeki toplam spam sayısı X , Binom dağılımına uymaktadır:

$$X \sim \text{Binom}(n, \hat{p})$$

$$P(X = k) = C(n, k) \cdot \hat{p}^k \cdot (1 - \hat{p})^{n-k}$$

Beklenen değer ve varyans:

$$E[X] = n \cdot \hat{p} \quad \text{Var}(X) = n \cdot \hat{p} \cdot (1 - \hat{p})$$

Parametre	Formül	Değer
$\hat{p}$ (MLE tahmini)	Spam sayısı / n	0.3099
$E[X]$ — Bernoulli	$\hat{p}$	0.3099
$\text{Var}(X)$ — Bernoulli	$\hat{p} (1 - \hat{p})$	0.2139

$E[X]$ — Binom	$n \cdot p^\wedge$	1426.0
$Var(X)$ — Binom	$n \cdot p^\wedge \cdot (1 - p^\wedge)$	984.0
$Std(X)$ — Binom	$\sqrt{n \cdot p^\wedge \cdot (1 - p^\wedge)}$	31.4

Tablo 3. Bernoulli ve Binom modellerinin parametre tahminleri ($n = 4601$).

3.4 Merkezi Limit Teoremi (MLT)

n yeterince büyük olduğunda Binom dağılımı Normal dağılıma yaklaşır (De Moivre-Laplace Teoremi):

$$Binom(n, p) \rightarrow N(n \cdot p, n \cdot p \cdot (1 - p)) \text{ } n \text{ büyük için}$$

Yaklaşımın geçerliliği için gereken koşul: $n \cdot p^\wedge \geq 5$ ve $n \cdot (1 - p^\wedge) \geq 5$. Veri setimizde $n \cdot p^\wedge = 1426$ ve $n \cdot (1 - p^\wedge) = 3175$ olduğundan bu koşullar fazlasıyla sağlanmaktadır.

MLT aynı zamanda Cross Validation bağlamında da anlam kazanmaktadır: her fold'da hesaplanan accuracy değeri, o fold'un test setindeki ~921 bağımsız Bernoulli denemesinin ortalamasıdır. MLT gereği bu ortalamalar normal dağılıma yaklaşır.

3.5 Hipotez Testleri

Modelin başarımını istatistiksel olarak sınamak için iki yöntem uygulanmıştır.

Binom Testi (kesin, parametrik olmayan): $H_0: p = 0.5$ varsayımı altında, n tahmin içinde k veya daha fazla doğru yapma olasılığı Binom dağılımının kuyruk olasılığı olarak hesaplanır:

$$p\text{-değeri} = P(X \geq k \mid X \sim Binom(n, 0.5))$$

Z-Testi (MLT yaklaşımı): n yeterince büyük olduğunda gözlemlenen accuracy'nin standartlaştırılmış değeri standart Normal dağılıma uyar:

$$z = (p^\wedge - p_0) / SE, SE = \sqrt{(p_0(1 - p_0) / n)}$$

Güven Aralığı: Uç olasılık değerlerinde Wald yaklaşımından daha güvenilir sonuçlar üreten Wilson yöntemi tercih edilmiştir.

3.6 Gaussian Naive Bayes Sınıflandırıcısı

GNB, her özelliğin sınıfa koşullu bağımsız ve Normal dağıldığını varsayar. Posterior olasılık Bayes teoremiyle hesaplanır:

$$P(spam \mid x_1, \dots, x_{57}) = P(spam) \cdot \prod P(x_j \mid spam)$$

GNB'nin spam tespiti için tercih edilmesinin temel nedeni, Bernoulli/Binom istatistiksel çerçevesiyle olan teorik uyumdur. Her özellik için ayrı bir koşullu dağılım öğrenen model, olasılıksal yapısı sayesinde istatistiksel yorumlamaya elverişlidir. Ayrıca 57 boyutlu özellik uzayında eğitim ve tahmin süreçleri hesaplama açısından verimlidir; küçük veri setlerinde dahi iyi genelleme yapabilmektedir.


Model eğitiminde dikkat edilen başlıca noktalar şunlardır: sınıf oranlarının hem eğitim hem de test setinde korunması için stratified split uygulanmış; tüm rastlantısal işlemlerde random_state=42 kullanılarak sonuçların tekrar edilebilirliği sağlanmıştır. Test seti toplam 921 email içermekte olup spam/ham oranı orijinal veri setiyle örtüşmektedir.

Performans değerlendirmesinde accuracy'nin yanı sıra precision, recall ve F1 skoru da hesaplanmıştır. Sınıf dengesizliği (%31 spam / %69 ham) nedeniyle tek başına accuracy yanıltıcı olabileceğinden, bu ek metrikler modelin gerçek başarımını daha kapsamlı biçimde yansıtmaktadır. Ek olarak 5-Fold Cross Validation uygulanmış; bu yöntem hem model stabilitesini hem de MLT doğrulamasını mümkün kılmıştır.

4. Analiz ve Sonuçlar

4.1 Binom Dağılımı Analizi

$X \sim \text{Binom}(4601, 0.3099)$ modeli altında beklenen spam sayısı $E[X] = 1426.0$, gözlemlenen spam sayısı da 1426'dır. Bu mükemmel örtüşme MLE tahmininin tutarlılığını sayısal olarak doğrulamaktadır.



Şekil 3. Sol: $\text{Binom}(4601, 0.31)$ PMF ve $N(1426, 984)$ Normal yaklaşımı; dikey çizgi gözlemlenen spam sayısını göstermektedir. Sağ: Spam ve ham sınıflarında ünlem işareti frekansı dağılımı.

Şekil 3'ün sol panelinde Binom PMF ile Normal yaklaşım eğrisi birlikte gösterilmektedir. Gözlemlenen spam sayısının dağılımının beklenti bölgesine tam düştüğü ve Normal eğrisinin PMF sütunlarını iyi örttüğü görülmektedir. Bu, söz konusu parametreler için MLT yaklaşımının güvenilir biçimde çalıştığını görsel olarak doğrulamaktadır.

Sağ panel, Bernoulli modelinin özellik düzeyindeki yorumunu sunmaktadır. Ünlem işareti frekansı spam emaillerinde ham emailere kıyasla belirgin biçimde yüksektir; ancak iki dağılım arasında örtüşme de mevcuttur — bu durum, modelin bu özellik üzerinde mükemmel olmayan bir başarımla sergileyeceğine işaret etmektedir.

4.2 Model Performansı

Model 921 emaillik test seti üzerinde değerlendirilmiştir:


Metrik	Değer
Accuracy	0.9099 (838 / 921 doğru)
Precision (Spam)	0.7837
Recall (Spam)	0.9789

F1 Score (Spam)	0.8705
F1 Score (Ham)	0.9309
5-Fold CV Ortalama	0.9098 ± 0.0093

Tablo 4. Gaussian Naive Bayes modelinin test seti performans metrikleri.

Model %91.0 accuracy değerine ulaşmıştır. Basit çoğunluk sınıfı tahminiyle elde edilebilecek %69 accuracy'ye kıyasla 22 puanlık bir artışa karşılık gelmektedir. Precision (0.78) ve Recall (0.98) arasındaki fark dikkat çekicidir: model gerçek spamların büyük çoğunluğunu yakalamakta ancak bazı ham emaileri yanlışlıkla spam olarak işaretlemektedir. Spam filtresi perspektifinden yüksek recall genellikle tercih edilen bir özelliktir.

4.3 Confusion Matrix Analizi



Şekil 4. Test seti confusion matrix. Parantez içi değerler sınıf içi oranları göstermektedir.

Confusion matrix incelendiğinde ham emailerin %88.1'inin, spam emailerin ise %97.9'unun doğru sınıflandırıldığı görülmektedir. Ham emailerde hata oranı (%12.1), spam emailerdeki hata oranından (%2.1) yaklaşık altı kat yüksektir. Bu asimetri, modelin spam sınıfına hafif bir yatkınlık taşıdığını ortaya koymaktadır.

4.4 Hipotez Testleri ve p-Değerleri

Modelin başarımının istatistiksel anlamlılığını sınamak için tek taraflı hipotez testi kurulmuştur:

$$H_0: p_{accuracy} = 0.5 \text{ (model şans tahminiyle eşdeğer)}$$

$$H_1: p_accuracy > 0.5 \text{ (model şans tahminiyle eşdeğer değil)}$$

$$\alpha = 0.05$$

Binom Testi: $n = 921$ tahmin, $k = 838$ doğru, H_0 altında $X \sim \text{Binom}(921, 0.5)$. Gözlemlenen veya daha uç bir sonuç elde etme olasılığı:

$$p\text{-değeri} = P(X \geq 838 \mid \text{Binom}(921, 0.5)) = 3.79 \times 10^{-158}$$

Bu p -değeri sayısal hassasiyet sınırlarına ulaşmaktadır. H_0 son derece güçlü biçimde reddedilmektedir.

Z-Testi: $n = 921$ büyük olduğundan Normal yaklaşım geçerlidir:

$$SE = \sqrt{(0.5 \times 0.5 / 921)} = 0.01648$$

$$z = (0.9099 - 0.5) / 0.01648 = 24.88$$

Her iki testten elde edilen sonuçlar tamamen tutarlıdır.

4.5 Güven Aralığı

Model accuracy'si için %95 Wilson güven aralığı hesaplanmıştır:

$$p^{\wedge} = 0.9099 \text{ \%95 Wilson GA: } [0.8896, 0.9267]$$

H_0 altındaki değer $p_0 = 0.5$, güven aralığının oldukça dışındadır. Güven aralığının dar olması (genişlik ≈ 0.037) modelin tutarlı ve stabil bir başarımleri sergilediğini göstermektedir.

Test	Gözlem	p-değeri	Karar
Binom Testi (kesin)	$k=838, n=921, p_0=0.5$	3.79×10^{-158}	H_0 reddedilir
Z-Testi (MLT)	$z = 24.88$	≈ 0.00	H_0 reddedilir
%95 Wilson GA	$p^{\wedge} = 0.9099$	$[0.8896, 0.9267]$	$p_0=0.5$ dışında

Tablo 5. Hipotez testleri ve güven aralığı özet tablosu.

4.6 5-Fold Cross Validation ve MLT Doğrulaması

Tek bir train/test bölünmesine dayanan değerlendirmenin örnekleme varyansına bağlı olabileceği göz önünde bulundurularak model başarımleri 5-Fold CV ile sistematik biçimde değerlendirilmiştir:


Fold	Accuracy
Fold 1	0.9218

Fold 2	0.9033
Fold 3	0.9065
Fold 4	0.8978
Fold 5	0.9196
Ortalama $\pm$ Std	0.9098 $\pm$ 0.0093

Tablo 6. 5-Fold Cross Validation sonuçları.

Accuracy değerleri 0.8978 ile 0.9218 arasında değişmekte ve standart sapma oldukça küçük kalmaktadır (0.0093). Bu durum modelin farklı veri alt kümelerinde tutarlı biçimde iyi performans sergilediğini göstermektedir.

Bölüm 4-5 — Hipotez Testleri ve Cross Validation Analizi



Şekil 5. Üst sol: CV fold accuracy değerleri. Üst orta: CV dağılımı ve Normal fit. Üst sağ: Q-Q plot (Shapiro-Wilk $p=0.44$). Alt sol: Binom testi görselleştirmesi. Alt sağ: %95 güven aralığı.

MLT doğrulaması: Her fold'daki accuracy, ~ 921 bağımsız Bernoulli denemesinin ortalamasıdır. Shapiro-Wilk testi ($W = 0.9052$, $p = 0.4395 > 0.05$) normallik varsayımının reddedilemeyeceğini ortaya koymuştur; bu bulgu MLT'nin söz konusu bağlamda geçerli olduğunu desteklemektedir. Şekil 5'teki Q-Q plot'ta veri noktalarının teorik Normal çizgisine yakın seyrettiği de görülmektedir.

5. Tartışma

5.1 Bulguların Yorumlanması

Elde edilen sonuçlar genel olarak tutarlı ve beklentilerle örtüşen bir tablo ortaya koymaktadır. MLE ile tahmin edilen $p^{\wedge} = 0.31$ gerçek dağılımı doğru yansıtmakta; Binom modelinin beklenen değeri gözlemlenen spam sayısı ile tam örtüşmektedir. Bu durum, Bernoulli/Binom çerçevesinin bu veri setine uygun olduğunu göstermektedir.

Gaussian Naive Bayes modelinin %91.0 accuracy değeri, basit çoğunluk sınıfı tahminiyle elde edilebilecek %69 accuracy'den belirgin biçimde yüksektir. Bu 22 puanlık fark istatistiksel olarak son derece anlamlıdır ($p < 10^{-150}$). Ayrıca 5-Fold CV'nin dar standart sapması (± 0.009), bu başarımın tek bir bölünmeye özgü olmadığını ve genellenebilir olduğunu ortaya koymaktadır.

5.2 Varsayımlar ve Sınırlamalar

Gaussian Normallik Varsayımı: GNB her özelliğin sınıfa koşullu Normal dağıldığını varsayar; oysa kelime frekansları tipik olarak log-normal ya da üstel dağılım sergilemektedir. Bu uyumsuzluk, ham emailerin hata oranının (%12.1) spam emailerin hata oranından (%2.1) altı kat yüksek olmasıyla kendini göstermektedir.

Bağımsızlık Varsayımı: Naive Bayes özelliklerin birbirinden bağımsız olduğunu kabul eder; ancak email metinlerinde bu varsayım kısıtlayıcı olabilir. "free" ve "money" gibi kelimelerin birlikte geçmesi, her birinin bağımsız varlığından daha güçlü bir spam sinyali taşıyabilir. Korelasyon matrisi bazı özellik çiftleri arasında küçük ama sıfırdan farklı korelasyonlar olduğunu göstermektedir.

MLT Testinin Gücü: Shapiro-Wilk testi yalnızca 5 fold üzerinde uygulanmıştır. Bu kadar küçük örneklemede normallik testinin istatistiksel gücü düşüktür; daha güvenilir bir MLT doğrulaması için 10-Fold CV önerilmektedir.

Sınıf Dengesizliği: %31 spam/%69 ham oranı, accuracy metriğini çoğunluk sınıfı lehine olumlu yönde etkileyebilir. Precision-Recall dengesi bu açıdan daha bilgi içerikli bir değerlendirme kriteridir.

5.3 Genel Değerlendirme

Sonuçlar bir bütün olarak değerlendirildiğinde, istatistiksel modelleme yaklaşımının spam tespiti problemine anlamlı katkılar sunduğu görülmektedir. Bernoulli/Binom çerçevesi veriyi tutarlı biçimde açıklamış; hipotez testleri modelin başarımının tesadüfe bağlı olmadığını kanıtlamıştır. Bununla birlikte GNB'nin belirli varsayımlarının veri dağılımıyla tam örtüşmediği de açıktır.

6. Sonuç

Bu projede UCI Spambase veri seti üzerinde Bernoulli ve Binom dağılımı çerçevesinde istatistiksel bir analiz gerçekleştirilmiş; Gaussian Naive Bayes sınıflandırıcısının başarımı hipotez testleri ve Cross Validation yöntemleriyle değerlendirilmiştir. Ana bulgular şu şekilde özetlenebilir:

- Her email bağımsız bir Bernoulli denemesi olarak modellenmiş, MLE ile $p^{\wedge} = 0.31$ tahmin edilmiştir. Tahmin edilen beklenen değer gözlemlenen spam sayısı (1426) tam örtüşmektedir.
- Spam sayısını modelleyen $\text{Binom}(4601, 0.31)$ dağılımı, MLT gereği $N(1426, 984)$ dağılımına yaklaşmaktadır; gerekli koşullar fazlasıyla sağlanmaktadır.
- Gaussian Naive Bayes modeli test setinde %91.0 accuracy elde etmiştir. Binom testi ($p = 3.79 \times 10^{-158}$) ve Z-testi bu başarımın istatistiksel olarak anlamlı olduğunu ortaya koymuştur. %95 Wilson GA: [0.8896, 0.9267].
- 5-Fold CV ortalaması 0.9098 ± 0.0093 bulunmuş; Shapiro-Wilk normallik testi ($p = 0.44$) CV değerlerinin Normal dağılıma uyumlu olduğunu göstererek MLT beklentisini desteklemiştir.

Gelecekteki çalışmalar için öneriler: Logistic Regression ve Random Forest gibi modeller karşılaştırma amacıyla uygulanabilir. Sınıf dengesizliği nedeniyle ROC-AUC ve PR-AUC metrikleri ek bilgi sunabilir. Kelime frekanslarının gerçek dağılımına uygun Multinomial Naive Bayes denenebilir. MLT doğrulamasını güçlendirmek için fold sayısı 10'a çıkarılabilir.

7. Kaynaklar

Veri Seti

Cranor, L. F., & LaMacchia, B. A. (1998). Spam! Communications of the ACM, 41(8), 74–83.
<https://doi.org/10.1145/280324.280336>

Dua, D., & Graff, C. (2019). UCI Machine Learning Repository. University of California, Irvine.
<https://archive.ics.uci.edu/ml/datasets/spambase>

Yazılım Kütüphaneleri

Harris, C. R. ve diğ. (2020). Array programming with NumPy. Nature, 585(7825), 357–362.

McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proc. 9th Python in Science Conference, 56–61.

Pedregosa, F. ve diğ. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Virtanen, P. ve diğ. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. Nature Methods, 17, 261–272.

İstatistik ve Makine Öğrenmesi

DeGroot, M. H., & Schervish, M. J. (2012). Probability and Statistics (4. baskı). Pearson.

Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). Probability and Statistics for Engineers and Scientists (9. baskı). Pearson.

Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.